Machine Learning

Projets notés

Printemps 2026

Ce projet a pour but de faire pratiquer les méthodologies typiques de l'approche « Data Science » pour la classification de données. Chaque groupe d'étudiants **aura un ensemble de données imposé et un autre au choix**.

Vous devrez réaliser votre projet avec la librairie *scikit-learn* (Python ; voir https://scikit-learn.org/stable/install.html) et plus particulièrement entraîner les modèles du plus proche voisin (PPV) et le Perceptron Multi-Couche (PMC). Dans *CyberLearn* vous avez le fichier ***exemplesScikit.pdf*** qui donne quelques exemples.

La liste des classes de *Scikit* se trouve à la page : http://scikit-learn.org/stable/modules/classes.html.

Pour le modèle **PPV** : https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html.

Pour les **PMC** : http://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html.

Pour le **codage des classes** (les sorties des modèles), il faudra vous familiariser avec https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html. L'idée sous-jacente étant que si on doit par exemple coder trois classes on utilise un vecteur (1, 0, 0) pour la première classe, (0, 1, 0) pour la deuxième et (0, 0, 1) pour la troisième.

Pour chaque modèle avant de réaliser l'apprentissage, il faudra **normaliser** les données ; dans ce but il faudra vous familiariser avec la classe `sklearn.preprocessing.normalize` (https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.normalize.html).

L'évaluation des modèles se fera en utilisant la procédure de **validation croisée** à 5 segments répétée 5 fois (pour un total de 25 entraînements). Dans *Scikit-Learn* regarder dans `sklearn.model.selection` (https://scikit-learn.org/stable/model_selection.html) et https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.KFold.html. Dans les rapports il s'agira de nous donner les **moyennes** et les **écarts types** (standard deviation).

Notez que tous les modèles présentent un certain nombre de paramètres. Comment choisit-on ces paramètres ? Par exemple pour le PPV on pourrait comparer le **TCC** (taux de classification correct) pour plusieurs valeurs du paramètre définissant le **nombre de voisins** à utiliser.

Pour le PMC il faudra faire **varier le nombre de neurones** dans une seule couche intermédiaire (exemple : 5, 10, 15, …) et lutter contre le **sur-apprentissage** en utilisant le **early-stopping**

(paramètre dans https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html).

On vous donne le droit de choisir un jeu de données imposé parmi les fichiers suivants (dans *CyberLearn*) :

- australian.data
- breast.data
- heart.data
- heart_failure.data (https://archive.ics.uci.edu/dataset/519/heart+failure+clinical+records)
- diabetes_early.data (https://archive.ics.uci.edu/dataset/529/early+stage+diabetes+risk+prediction+dataset)

La validation croisée sera appliquée pour toute les données utilisées, la dernière colonne des fichiers désignant la classe.

En plus d'un jeu de données imposé il faudra choisir un deuxième jeu de données. Ces données libres peuvent se trouver sur le site https://archive.ics.uci.edu/ml/index.php. Il doit y avoir au moins deux classes, au moins dix variables et au moins 300 données. Evitez de prendre un ensemble de données avec plus de 20000 exemples. Toute exception violant ces contraintes reste possible sur demande à l'enseignant.

Ce travail est noté ; il devra être déposé dans *Cyberlearn*. Une archive contenant le rapport et le code devra avoir un **nom indiquant tous les auteurs**.

Pour la présentation orale du projet vous devrez respecter certaines contraintes par rapport aux slides à présenter :

- 1 slide sur le pré-traitement des données
- 1-2 slides pour les configurations des modèles
- 3-4 slides pour les résultats
- la conclusion se fera oralement (sans slides)

Dans le **rapport** il n'est pas demandé d'expliquer les modèles. Il sera simplement question de montrer les résultats expérimentaux. On s'attend à voir la description des traitements réalisés sur les données avant l'apprentissage et puis des tableaux ou des graphiques montrant les résultats obtenus par validation croisée, en faisant varier certains paramètres du modèle. Enfin, il faudra réaliser une analyse des résultats sous forme de discussion.

Date de rendu : au plus tard, le **dimanche 29 mars 2026**.